INFORME TÉCNICO · MODELO PREDICTIVO

Predicción mensual de demanda turística

Evaluación temporal, comparación de modelos y pronósticos para municipios del Chocó

Síntesis. Se propone un sistema de apoyo a la planificación turística que predice el flujo mensual de llegadas aéreas y clasifica la temporada de demanda en los siete municipios disponibles. El proyecto integra diferentes fuentes para estudiar el turismo, pero no confunde los flujos aéreos con el total de visitantes.

1. Problema y objetivo

La actividad turística del Chocó cambia de un mes a otro y entre municipios, por lo que la planificación de servicios, infraestructura y temporadas requiere reconocer patrones históricos y anticipar períodos de mayor movimiento.

Objetivo general: desarrollar y evaluar modelos que pronostiquen, por municipio y mes, un indicador cuantitativo de afluencia turística y su clasificación en demanda alta, media o baja, usando registros históricos y variables de calendario.

2. Variable objetivo y salidas

Elemento	Definición
Target de regresión	`llegadas`: pasajeros aéreos que arriban al municipio en un mes.
Salida numérica	Estimación mensual no negativa de llegadas por municipio.
Salida de demanda	Baja, Media o Alta, usando los terciles recientes del propio municipio, calculados únicamente con datos de entrenamiento.
Horizonte	Julio–diciembre de 2026 y enero–diciembre de 2027: **126 pronósticos** municipio–mes.

3. Dataset oficial documentado

La fuente principal corresponde a registros de Aerocivil, documentados institucionalmente en el portal de transporte aéreo comercial: `https://www.datos.gov.co/d/gb6w-ynu4`. Los archivos analizados se encuentran dentro del entregable, en `datos/`. La información de visitantes extranjeros no residentes se contextualiza mediante los informes turísticos de MinCIT.

606 registros aeropuerto-mes ⟶ 494 observaciones municipio-mes ⟶ 7 municipios

El historial observado cubre enero de 2020 a junio de 2026. En 2026 se dispone de seis meses observados; se excluyen los meses posteriores del entrenamiento inicial.

4. Features y preparación

4.1 Variables empleadas

Grupo / variable	Razón de incorporación
`municipio`	Captura diferencias estructurales en el volumen de movimiento. Se codifica con *OneHotEncoder*.
`anio`, `mes_num`	Permiten aprender evolución temporal y estacionalidad mensual. Mes también se codifica como categoría.
`mes_sin`, `mes_cos`	Describen la naturaleza cíclica del calendario anual, evitando una ruptura artificial entre diciembre y enero.
`dias_fiesta`, `dias_ballenas`	Representan días de eventos locales y temporada ambiental incluidos en el calendario del proyecto.
`dias_festivo_nac`, `puentes`, `semana_santa_dias`	Incorporan posibles condiciones estacionales conocidas antes de elaborar el pronóstico.

4.2 Transformaciones

- Validación de claves `municipio--anio--mes_num` y correspondencia de nueve códigos aeroportuarios con siete municipios.
- Unión del calendario mediante claves únicas; registros sin calendario válido no se completan arbitrariamente.
- Ajuste del modelo con respuesta transformada: $z = \log(1 + \text{llegadas})$. Predicción invertida: $\widehat{y} = \max\{0, \exp(\widehat{z}) - 1\}$.
- Codificación *one-hot* de municipio y mes; variables continuas y días de calendario ingresan al pipeline sin transformaciones aprendidas del conjunto de prueba.

4.3 Prevención de filtración temporal

No se incluyen como predictores las `salidas` ni las `llegadas` reales del mismo mes, ni los visitantes extranjeros observados en ese período. El RNT describe un corte estático cuya fecha histórica no está determinada. Ambos conjuntos se conservan en el EDA; su utilidad adicional se prueba por separado.

Regla del experimento: cada prueba usa solo información conocida antes de sus meses objetivo. Se entrena hasta 2024 para evaluar 2025 y hasta 2025 para examinar enero–junio de 2026.

5. Modelos comparados y diseño temporal

5.1 Cinco enfoques complementarios

Modelo	Lógica
Mediana estacional	Mediana histórica de llegadas por municipio y mes; alternativa simple y robusta.
Mismo mes del año anterior	Valor observado en el mismo mes previo; usa mediana histórica cuando falta ese registro.
Referencia estacional suavizada	Combinación de **90 %** del mismo mes del año anterior y **10 %** del mismo mes de dos años atrás, con tratamiento de faltantes.
Random Forest sin festividades	Ensamble de árboles con variables territoriales y temporales.
Random Forest con festividades	Ensamble anterior más calendario de eventos, puentes y temporada de ballenas.

6. Ajuste de hiperparámetros

Los Random Forest se compararon en una búsqueda manual acotada. Para cada variante se probaron estas configuraciones sobre entrenamiento hasta 2023 y **validación en 2024**, sin seleccionar parámetros usando 2025 ni 2026.

Árboles	Hoja mínima	Max. features	WAPE validación 2024 (RF con fest.)
160	2	0,8	15,83 %
160	4	0,8	16,56 %
240	**3**	**1,0**	**14,66 %** (seleccionado)

Para la referencia suavizada se evaluaron pesos del segundo año entre 0 y 0,50, en pasos de 0,05. Se seleccionó **0,10** por su WAPE de **13,70 % en 2024**.

6.1 Cortes de validación

- **2024:** 84 registros, selección de configuración; la categoría de demanda fue estimable en 72.
- **2025:** 82 registros, prueba principal independiente de la selección.
- **Enero–junio 2026:** 40 registros, seguimiento adicional, no año completo.

7. Métricas y resultados

Se reportan tres indicadores: **MAE** (error absoluto medio en pasajeros), **WAPE** (error absoluto agregado sobre el total observado) y **acierto de demanda** (porcentaje de categorías Baja/Media/Alta correctamente previstas).

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \widehat{y}_i|, \qquad \text{WAPE} = 100\,\frac{\sum_i |y_i - \widehat{y}_i|}{\sum_i y_i}.$$

7.1 Prueba independiente: 2025 (82 registros)

Modelo	WAPE	MAE	Acierto demanda
Mediana estacional	15,32 %	505,95	46,34 %
Mismo mes del año anterior	10,51 %	347,10	60,98 %
Referencia suavizada	**10,29 %**	**339,74**	62,20 %
RF sin festividades	13,43 %	443,49	63,41 %
RF con festividades	12,75 %	421,24	**64,63 %**

7.2 Comprobación: enero–junio 2026 (40 registros)

Modelo	WAPE	MAE	Acierto demanda
Mismo mes del año anterior	8,45 %	253,03	67,50 %
Referencia suavizada	8,15 %	244,19	65,00 %
RF sin festividades	8,74 %	261,92	**72,50 %**
RF con festividades	**7,85 %**	**235,13**	70,00 %

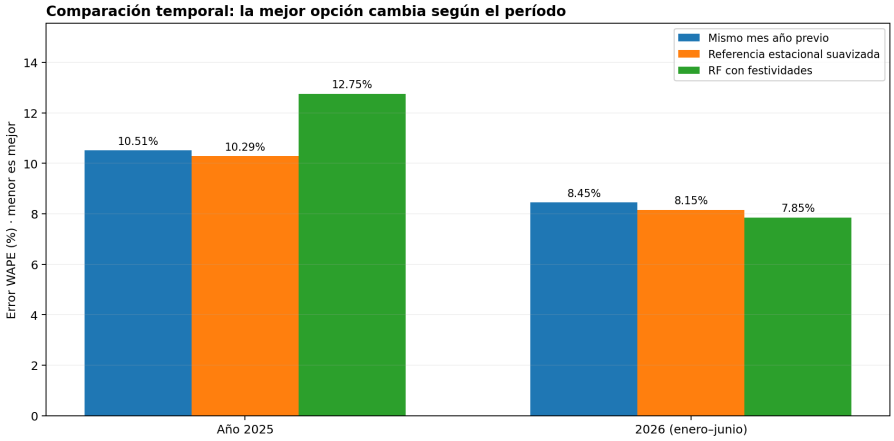


Figura 1. Comparación de WAPE en 2025 y 2026 parcial, extraída de los resultados del proyecto.

Lectura: la referencia suavizada da el menor error numérico en 2025; el RF con festividades gana en WAPE durante el seguimiento 2026 y tiene el mayor acierto de demanda en 2025.

8. Interpretación del Random Forest

8.1 Contribución de variables en el modelo final

La importancia por disminución de impureza del pipeline serializado, agrupada según su origen, queda así. Las cantidades son descriptivas del **modelo ajustado con 494 registros hasta junio de 2026** y no prueban causalidad.

Familia de features	Importancia acumulada
Municipio (categorías codificadas)	**72,65 %**
Año	15,99 %
Mes (categorías + seno/coseno)	9,14 %
Festividades, ballenas y festivos	2,22 %

Interpretación: las diferencias de escala entre municipios explican gran parte de las decisiones del modelo. El calendario aporta información adicional, pero su importancia numérica es menor. La importancia por impureza puede favorecer grupos de variables con más categorías; no es un efecto causal.

8.2 Observado frente a estimado

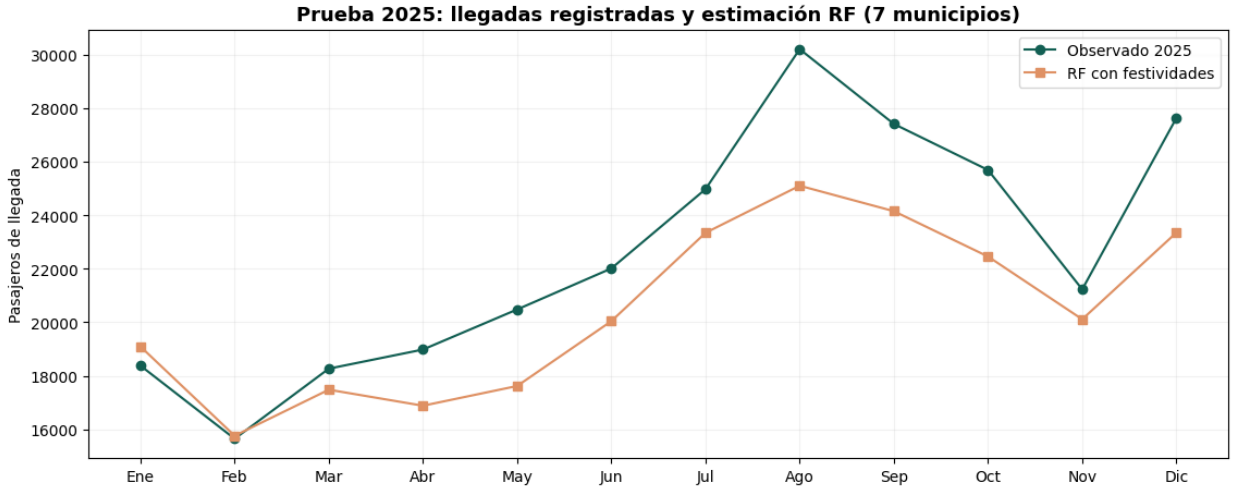


Figura 2. Llegadas observadas y pronóstico RF por mes, agregados para la prueba 2025.

Las predicciones reproducen el nivel general de actividad, aunque presentan discrepancias en ciertos meses. Por ello se mantienen dos salidas de evaluación: error de cantidad y acierto al clasificar temporadas.

8.3 Cómo se asigna una temporada

Para cada municipio se calculan los cuantiles de **1/3 y 2/3** con el historial reciente disponible en el entrenamiento. Una predicción bajo el primer umbral es *Baja*; entre umbrales, *Media*; por encima del segundo, *Alta*. Estas categorías son **relativas a cada municipio**.

9. Aporte de los datos integrados

Se probaron variantes de Random Forest con RNT y perfiles históricos de visitantes extranjeros, construidos sin usar conteos futuros. Los resultados no justificaron sustituir el modelo seleccionado.

Variante	WAPE 2025	WAPE 2026 ene–jun
RF + festividades	**12,75 %**	7,85 %
RF + festividades + RNT	12,81 %	**7,78 %**
RF + festividades + extranjeros históricos	12,97 %	8,28 %
RF + todas las fuentes	13,03 %	8,30 %

La mejora marginal del RNT en el semestre de 2026 no se repite en 2025 y ese archivo carece de fecha histórica del corte. Por ello, **RNT y visitantes extranjeros permanecen en el análisis exploratorio**, y las festividades se conservan en el Random Forest desplegable.

10. Pronósticos generados

Con el modelo reentrenado usando los **494 registros observados hasta junio de 2026**, se produjeron **126 predicciones** para siete municipios y 18 meses. La suma de estimaciones de 2027 es de aproximadamente **263.668 llegadas aéreas**.

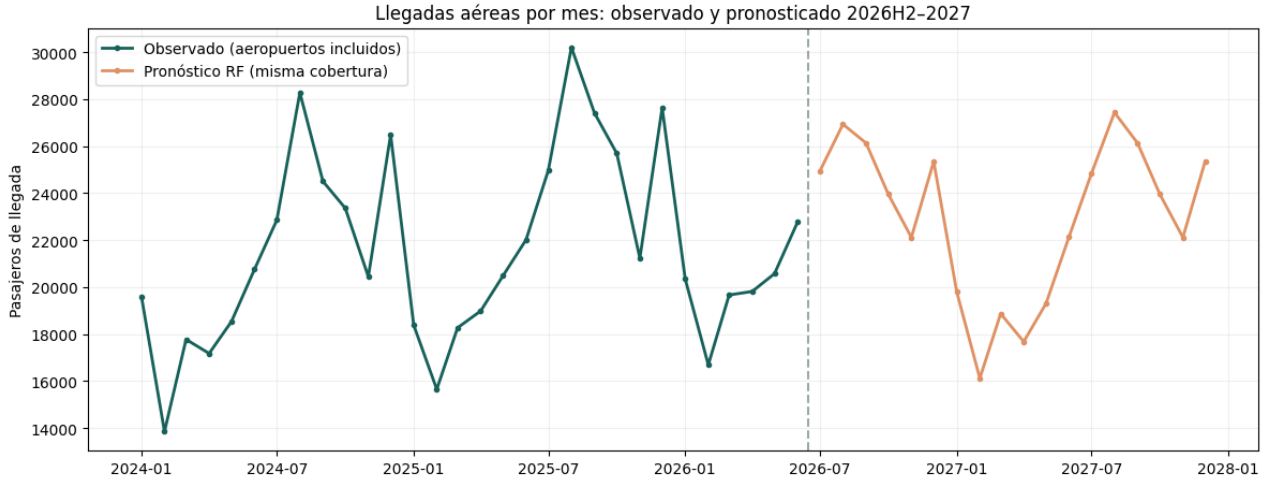


Figura 3. Serie observada y proyección agregada a diciembre de 2027.

Se entrega además una referencia estacional suavizada para contrastar escenarios. En los meses de 2027, parte de sus valores se construyen recursivamente a partir de pronósticos previos; esta característica se declara en el archivo de comparación.

Archivos de resultados

`resultados_municipales/pronostico_comparativo_dos_modelos.csv`; `resultados_municipales/pronostico_llegadas_2026H2_2027.csv`; `resultados_predictivo/modelo_llegadas_rf_festividades.joblib`.

11. Limitaciones y uso ético

- **Alcance del target:** la variable registra pasajeros aéreos, incluidos viajes no turísticos; no mide el total de turistas nacionales e internacionales ni las vías terrestres y fluviales.
- **Representatividad:** la serie comprende siete municipios; Juradó posee solo 30 meses observados, por lo que sus proyecciones tienen una base más débil.
- **Temporalidad:** el seguimiento de 2026 cubre únicamente seis meses. Eventos extraordinarios, cambios de conectividad o impactos climáticos pueden modificar los resultados futuros.
- **Transparencia:** no deben presentarse estimaciones académicas como cifras oficiales ni atribuir causalidad a festividades o RNT por su simple asociación estadística.
- **Equidad y privacidad:** la herramienta trabaja con datos agregados municipales, sin personas identificables. Se recomienda acompañar decisiones sobre municipios de menor cobertura con revisión humana y fuentes locales.

12. Conclusión técnica

Decisión: conservar *Random Forest con festividades* como modelo de Machine Learning para clasificar temporadas, y publicar la *referencia estacional suavizada* como comparación de cantidades. Esta elección reconoce los resultados reales de cada período, evita filtración temporal y permite comunicar incertidumbre.

13. Reproducibilidad y fuentes

Archivo o script	Función
`integrar_fuentes.py`	Integra movilidad, visitantes, RNT y calendario.
`modelo_afluencia.py`	Prepara datos, ajusta RF, evalúa y genera predicciones.
`evaluar_variables_integradas.py`	Compara conjuntos de predictores.
`evaluar_enfoque_estacional.py`	Ajusta y contrasta la referencia suavizada.
`resultados/comparacion_modelos_con_suavizado.csv`	Métricas por corte; evidencia numérica del informe.

Fuentes institucionales: Aerocivil, *Transporte Aéreo Comercial – Tráfico Origen-Destino*, https://www.datos.gov.co/d/gb6w-ynu4; MinCIT, *Informes de turismo*, https://www.mincit.gov.co/estudios-economicos/estadisticas-e-informes/informes-de-turismo; Portal de Información Turística de Colombia, https://portucolombia.mincit.gov.co/tematicas/estadisticas-territoriales/estadisticas-territoriales-de-turismo-1.

Nota de alcance: el origen institucional de las series se cita para documentar sus definiciones; las cantidades y métricas incluidas provienen de los archivos integrados y evaluados del entregable.